ผ่านการตรวจแล้ว แต่ผิด (Validated, yet Wrong): บทเรียนจากการทบทวนการตรวจสอบความถูกต้องของงานเมแทบอโลมิกส์สี่กรณี

คณิณ แคลวิณ ชมวิวัฒน์*[1] และ ชัยพร ออฤดี[1]

คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

เลขที่ 1 ซอยฉลองกรุง 1 แขวงลาดกระบัง เขตลาดกระบัง กรุงเทพฯ 10520

บทคัดย่อ

การศึกษานี้ทบทวนงานวิเคราะห์ด้วยการเรียนรู้ของเครื่อง (Machine Learning) สี่งานของผู้วิจัยเอง ซึ่งใช้ข้อมูลเมแทบอโลมิกส์ (Metabolomics) จาก NMR ขนาดเล็กที่เผยแพร่สาธารณะ แต่ละงานให้ผลที่ผู้วิจัยเคยถือว่าผ่านการตรวจสอบความถูกต้องแล้ว ได้แก่ ค่า *p* จากการทดสอบเรียงสับเปลี่ยน (Permutation Test) ที่ต่ำที่สุดเท่าที่การทดสอบจะให้ได้ เส้นโค้ง ROAR ที่ต่ำกว่าการตัดฟีเจอร์แบบสุ่ม หรือคะแนนสูงจากการตรวจสอบไขว้ (Cross-Validation) ที่แบ่งกลุ่มตามบุคคล แต่ในทั้งสี่งาน การตีความทางชีววิทยาที่ผู้วิจัยให้กับคะแนนนั้นไม่มีหลักฐานรองรับ หรือไม่สามารถระบุได้ แบบจำลองพยากรณ์ผู้ตอบสนองต่อการผ่าตัดที่ได้ค่า $p = 0.001$ จากวิธีที่ยังไม่ได้ตรวจการสอบเทียบ (Calibration) ทำได้ไม่ดีไปกว่าคะแนนอ้างอิงที่ไม่ต้องฝึกแบบจำลอง และความเชื่อมโยงระหว่างผลลัพธ์ที่คำนวณจากการเปลี่ยนแปลงกับฟีเจอร์ค่าตั้งต้น สามารถอธิบายสมรรถนะของแบบจำลองได้โดยไม่ต้องมีการตอบสนองที่พยากรณ์ได้ สารสามชนิดที่ยังไม่ทราบแหล่งที่มาแน่ชัดถูกจัดอันดับใกล้เคียงกับเมแทบอไลต์ที่เป็นที่ยอมรับในการเปรียบเทียบ ROAR เชิงสำรวจ ซึ่งไม่สามารถตัดสินแหล่งที่มาของฟีเจอร์ได้ สำหรับตัวจำแนกโรคเบาหวาน ข้อมูลไม่สามารถแยกได้ว่าสมรรถนะเกิดจากความแตกต่างของโรค หรือจากโปรโตคอลการเก็บตัวอย่างสองแบบที่แต่ละคลาสมาจาก และตัวจำแนก “โรคอ้วน” แท้จริงแล้วเปรียบเทียบผู้ป่วยก่อนและหลังการผ่าตัดลดน้ำหนัก ในข้อมูลจำลองที่ไม่มีการตอบสนองที่พยากรณ์ได้และความเที่ยงของการวัดต่ำ การทดสอบเรียงสับเปลี่ยนแบบสลับป้ายกำกับทั้งชุดปฏิเสธสมมติฐานความเป็นอิสระในร้อยละ 26 ของชุดข้อมูลเมื่อ $n = 50$ และร้อยละ 100 เมื่อ $n = 500$ ผู้วิจัยเสนอว่ารายงานการตรวจสอบความถูกต้องควรระบุคำอธิบายทางเลือกของคะแนนหลัก และระบุว่าการทดสอบใดใช้ตรวจคำอธิบายแต่ละข้อ พร้อมเสนอคำถามหกข้อสำหรับงานเมแทบอโลมิกส์ที่มีขนาดตัวอย่างเล็ก

คำสำคัญ: การตรวจสอบความถูกต้อง, เมแทบอโลมิกส์, การเรียนรู้ของเครื่อง, การทดสอบเรียงสับเปลี่ยน, การถดถอยเข้าหาค่าเฉลี่ย, การอธิบายฟีเจอร์, ตัวแปรกวน

---

* Author’s Email: 67070015@kmitl.ac.th

[1] นักศึกษา คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

1. บทนำ

1.1 ที่มาและความสำคัญ

ผลการวิเคราะห์แรกที่ผู้วิจัยนำมาทบทวนเป็นผลที่ผู้วิจัยเคยพอใจมาก ผู้วิจัยต้องการพยากรณ์จากตัวอย่างเลือดก่อนผ่าตัดเพียงครั้งเดียวว่า ผู้ป่วยผ่าตัดลดน้ำหนัก (Bariatric Surgery) คนใดจะเป็น “ผู้ตอบสนองดี” (Strong Responder) เมื่อครบหนึ่งปี แบบจำลองได้ค่า PR-AUC 0.683 เทียบกับความชุก (Prevalence) 0.437 ผู้วิจัยทำการตรวจสอบไขว้ทั้งหมดซ้ำ 1,000 ครั้ง โดยสลับป้ายกำกับ (Label) ของข้อมูลฝึกภายในแต่ละ Fold และฝึกแบบจำลองใหม่ทุกครั้ง ไม่มีรอบใดที่ได้ผลดีเท่าแบบจำลองจริง จึงได้ค่า $p = 0.001$ ซึ่งเป็นค่าต่ำที่สุดที่การสลับ 1,000 รอบจะให้ได้ ตามเกณฑ์การตรวจสอบที่ผู้วิจัยรู้จัก ผลนี้จึงดูเหมือนผ่านการตรวจสอบความถูกต้องแล้ว

ต่อมาผู้วิจัยเปรียบเทียบกับคะแนนอ้างอิงที่ไม่ต้องฝึกแบบจำลอง (Learn-Nothing Scorer) ซึ่งคำนวณด้วยกฎตายตัวจากค่าตั้งต้น (Baseline) ของผู้ป่วยแต่ละคนและทิศทางที่คาดหวังของสารบ่งชี้แต่ละตัวเท่านั้น คะแนนนี้ได้ 0.709 สูงกว่าแบบจำลองที่ฝึกแล้ว ผลการทดสอบเรียงสับเปลี่ยนเป็นเพียงสิ่งบ่งชี้ว่าฟีเจอร์กับป้ายกำกับมีความสัมพันธ์กัน แต่ไม่สามารถบอกได้ว่าความสัมพันธ์นั้นมาจากอะไร ป้ายกำกับถูกสร้างจากการเปลี่ยนแปลงระหว่างค่าตั้งต้นกับค่าติดตามผลของผู้ป่วยแต่ละคน และการสร้างป้ายกำกับในลักษณะนี้อาจทำให้ป้ายกำกับขึ้นกับค่าตั้งต้นผ่านความคลาดเคลื่อนของการวัดและการถดถอยเข้าหาค่าเฉลี่ย (Regression to the Mean) ความเชื่อมโยงนี้สามารถอธิบายสมรรถนะของแบบจำลองได้โดยไม่ต้องมีการตอบสนองทางชีววิทยาที่พยากรณ์ได้ และแบบจำลองที่ฝึกแล้วก็ไม่ได้ดีกว่าคะแนนอ้างอิงนี้

บทความนี้ว่าด้วยระยะห่างระหว่างการตรวจสอบที่ผ่านกับการตีความที่ถูกต้อง ผู้วิจัยทบทวนงานวิเคราะห์ข้อมูลสาธารณะสี่งานของตนเอง ซึ่งแต่ละงานดูเหมือนผ่านการตรวจสอบที่ผู้วิจัยใช้ และพบว่าในทั้งสี่งาน การตีความคะแนนของผู้วิจัยไม่มีหลักฐานรองรับ รายละเอียดเชิงเทคนิคและการศึกษาด้วยการจำลองฉบับเต็มอยู่ในบทความคู่กัน [1] ในบทความนี้ ผู้วิจัยนำเสนอทั้งสี่กรณีในฐานะข้อผิดพลาดที่เกิดขึ้นจริง เพราะการเข้าใจว่าข้อผิดพลาดรอดผ่านการตรวจสอบได้อย่างไร มีประโยชน์ต่อนักวิเคราะห์คนถัดไปมากกว่าวิธีแก้ไขเพียงอย่างเดียว ข้อกล่าวอ้างของบทความนี้มีขอบเขตแคบ ผู้วิจัยไม่ได้ประเมินว่าความล้มเหลวลักษณะนี้พบบ่อยเพียงใดในงานวิจัยที่ตีพิมพ์ แต่แสดงให้เห็นว่าความล้มเหลวนี้เกิดขึ้นได้ในงานที่ทำอย่างระมัดระวัง และการตรวจสอบเองก็ไม่ได้ส่งสัญญาณเตือนใด ๆ

1.2 วัตถุประสงค์ของการศึกษา

1.2.1 เพื่อทบทวนงานวิเคราะห์ด้วยการเรียนรู้ของเครื่องสี่งานของผู้วิจัย ที่ผ่านการตรวจสอบมาตรฐาน แต่การตีความทางชีววิทยาไม่มีหลักฐานรองรับ

1.2.2 เพื่อระบุว่าการตรวจสอบแต่ละแบบตอบคำถามใด และยังเปิดช่องให้คำอธิบายทางเลือกใด พร้อมเสนอวิธีควบคุมที่ตรงจุด

1.2.3 เพื่อเสนอแนวคำถามสำหรับการรายงานผลการตรวจสอบความถูกต้องในงานเมแทบอโลมิกส์ที่มีขนาดตัวอย่างเล็ก

1.3 ประโยชน์ที่คาดว่าจะได้รับ

1.3.1 ได้ตัวอย่างจริงของกรณีที่การตรวจสอบมาตรฐานผ่าน แต่การตีความผลไม่ถูกต้อง พร้อมวิธีควบคุมที่ใช้ตรวจจับ

1.3.2 ได้แนวคำถามที่นักวิเคราะห์สามารถนำไปใช้ก่อนรายงานคะแนนหลักของแบบจำลอง

2. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

การตรวจสอบสามแบบที่ผู้วิจัยใช้ทำหน้าที่ต่างกัน แต่ละแบบตรวจรูปแบบความล้มเหลวเฉพาะอย่างภายใต้สมมติฐานที่กำหนด และไม่มีแบบใดยืนยันการตีความทางชีววิทยาได้ทั้งหมด ตารางที่ 1 แสดงคำถามที่การตรวจสอบแต่ละแบบตอบ คำถามที่มักถูกเข้าใจว่าตอบ และคำอธิบายทางเลือกที่การตรวจสอบนั้นยังเปิดช่องไว้ในกรณีของผู้วิจัย

2.1 การตรวจสอบไขว้ (Cross-Validation)

การตรวจสอบไขว้ไม่ใช่การทดสอบสมมติฐาน แต่เป็นการประมาณว่าแบบจำลองพยากรณ์ตัวอย่าง

ตารางที่ 1 คำถามที่การตรวจสอบแต่ละแบบตอบ คำถามที่มักถูกเข้าใจว่าตอบ และคำอธิบายทางเลือกที่ยังเปิดอยู่ในกรณีของผู้วิจัย

การตรวจสอบ	คำถามที่ตอบ	คำถามที่มักถูกเข้าใจว่าตอบ	คำอธิบายทางเลือกที่ยังเปิดอยู่	กรณี
Label Permutation	ฟีเจอร์กับป้ายกำกับเป็นอิสระต่อกันหรือไม่	แบบจำลองพยากรณ์การตอบสนองรายบุคคลได้จริงหรือไม่	ป้ายกำกับที่คำนวณจากการเปลี่ยนแปลงขึ้นกับฟีเจอร์ค่าตั้งต้นผ่านการถดถอยเข้าหาค่าเฉลี่ย	1
ROAR	แบบจำลองพึ่งพาฟีเจอร์อันดับต้นหรือไม่	ฟีเจอร์อันดับต้นเป็นสัญญาณทางชีววิทยาหรือไม่	ฟีเจอร์อันดับต้นอาจสะท้อนการจัดการตัวอย่าง ร่วมกับหรือแทนสรีรวิทยา	2
Subject-Grouped CV	แบบจำลองพยากรณ์บุคคลใหม่ที่เก็บตัวอย่างด้วยวิธีเดียวกันได้ดีเพียงใด	คะแนนสะท้อนโรคหรือไม่	แต่ละคลาสเก็บตัวอย่างภายใต้โปรโตคอลของตนเอง	3
Subject-Grouped CV	เช่นเดียวกับข้างต้น	ป้ายกำกับมีความหมายตรงกับชื่อหรือไม่	ป้ายกำกับแทนการเปรียบเทียบอื่น	4

ที่ไม่ได้ใช้ฝึกได้ดีเพียงใด โดยตัวอย่างเหล่านั้นต้อง*เก็บด้วยวิธีเดียวกัน*กับตัวอย่างที่ใช้ฝึก การแบ่ง Fold ตามบุคคล (Subject-Grouped) ช่วยตรวจคำอธิบายทางเลือกหนึ่งข้อ คือแบบจำลองจำบุคคลได้แทนที่จะแยกคลาส หากตัวอย่างทุกตัวของคลาสหนึ่งถูกเก็บด้วยวิธีที่ต่างจากอีกคลาส การตรวจสอบไขว้ก็จะรายงานได้อย่างถูกต้องว่าความแตกต่างนั้นใช้ได้กับข้อมูลใหม่

2.2 การทดสอบเรียงสับเปลี่ยนป้ายกำกับ (Label Permutation Test)

การทดสอบเรียงสับเปลี่ยนป้ายกำกับทดสอบสมมติฐานว่างที่ว่าฟีเจอร์กับป้ายกำกับเป็นอิสระต่อกัน [2] ภายใต้สมมติฐานของการทดสอบ ค่า p ที่ต่ำเป็นหลักฐานว่ามีความสัมพันธ์*บางอย่าง* แต่ไม่ได้บอกว่าความสัมพันธ์นั้นมาจากไหน การสลับป้ายกำกับทำได้สองแบบ คือสลับป้ายกำกับทั้งชุดก่อนทำการตรวจสอบไขว้ [2] หรือเมื่อป้ายกำกับถูกกำหนดภายในแต่ละ Fold ก็สลับเฉพาะป้ายกำกับของข้อมูลฝึกในแต่ละ Fold โดยคงป้ายกำกับของข้อมูลทดสอบไว้ ในที่นี้ การสอบเทียบ (Calibration) หมายถึงการที่การทดสอบควบคุมอัตราการปฏิเสธเมื่อสมมติฐานว่างเป็นจริงได้ตามระดับนัยสำคัญที่กำหนดหรือไม่ การสอบเทียบของค่า p ที่ได้ขึ้นกับว่าใช้วิธีใด และควรระบุวิธีที่ใช้ไว้ในรายงาน

2.3 การอธิบายฟีเจอร์และ Remove-and-Retrain (ROAR)

SHAP และวิธีที่คล้ายกันจัดอันดับฟีเจอร์ตามส่วนที่ฟีเจอร์มีต่อการทำนายของแบบจำลอง ROAR [3] ตัดฟีเจอร์อันดับต้นออก ฝึกแบบจำลองใหม่ แล้วเปรียบเทียบสมรรถนะที่ลดลงกับการตัดฟีเจอร์แบบสุ่ม ROAR ถามว่าแบบจำลอง*พึ่งพา*ฟีเจอร์อันดับต้นหรือไม่ แต่ไม่ได้ถามว่าฟีเจอร์เหล่านั้นเป็นสัญญาณทางชีววิทยาหรือไม่

2.4 การถดถอยเข้าหาค่าเฉลี่ย Batch Effect และการรั่วไหลของข้อมูล

รูปแบบความล้มเหลวในกรณีของผู้วิจัยไม่ใช่เรื่องใหม่ การถดถอยเข้าหาค่าเฉลี่ยมีการอธิบายมาตั้งแต่อย่างน้อย ปี ค.ศ. 1962 [4] ความคลาดเคลื่อนของการวัดและความแปรผันรายวันทำให้ค่าตั้งต้นที่สูงหรือต่ำผิดปกติเคลื่อนกลับเข้าหาค่าเฉลี่ย ค่าตั้งต้นจึงดูเหมือนพยากรณ์การเปลี่ยนแปลงได้ แม้ไม่มีอะไรเกิดขึ้นจริง [5, 6] และคะแนนการเปลี่ยนแปลงที่มีพจน์ร่วมกับค่าตั้งต้นจะมีความเชื่อมโยงทางคณิตศาสตร์ (Mathematical Coupling) กับค่าตั้งต้น [7] Batch

Effect และ ผล จาก วิธี เก็บ ตัวอย่าง อาจ ปะปน (Confounded) กับ ตัวแปร ทาง ชีววิทยา ที่ สนใจ [8, 9] และ การ จัดการ ตัวอย่าง ก่อน การ วิเคราะห์ อาจทำให้มีสารจากภายนอกปนเข้ามาในตัวอย่าง [10, 11] การ รั่ว ไหล ของ ข้อมูล (Leakage) หลาย รูป แบบ ได้ รับ การ รวบรวม ไว้ ใน งาน วิทยาศาสตร์ ที่ใช้ การ เรียน รู้ ของ เครื่อง [12] และ แนวทาง การ รายงาน อย่าง TRIPOD+AI กำหนด ให้ ผู้ เขียน ระบุ นิยาม ของ ผลลัพธ์ และ ความ สัมพันธ์ กับ ตัวแปร ทำนาย [13]

2.5 จุดต่างของการศึกษานี้จากงานวิจัยที่ผ่านมา

งาน ที่ ผ่าน มา อธิบาย ปัญหา เหล่า นี้ ใน ภาพ รวม สิ่ง ที่ กรณี ของ ผู้ วิจัย เพิ่ม เติม คือ แต่ละ กรณี ผ่าน การ ตรวจ สอบ ที่ มัก ถือว่า เพียง พอ ใน งาน ของ นัก วิเคราะห์ที่รู้จักปัญหานี้ในภาพรวมแต่ไม่ได้สังเกตเห็นในข้อมูลของตนเอง ผู้วิจัยจับคู่ความล้มเหลวแต่ละแบบกับการตรวจสอบที่ผ่านและวิธีควบคุมที่ตรวจจับได้ และใช้การจำลองแสดงว่าวิธีแก้การถดถอยเข้าหาค่าเฉลี่ยที่นิยมใช้วิธีหนึ่งยังไม่เพียงพอ

3. วิธีการดำเนินงานวิจัย

3.1 ภาพรวมกระบวนการดำเนินงาน (Process Overview)

ผู้วิจัยทบทวนงานวิเคราะห์เดิมสี่งาน สำหรับแต่ละงาน ผู้วิจัย ระบุ ข้อ กล่าว อ้าง ตาม ที่ รายงาน ไว้ เดิม ระบุ การ ตรวจ สอบ ที่ งาน นั้น ผ่าน พิจารณา ว่า การ ตรวจสอบนั้นยังเปิดช่องให้คำอธิบายทางเลือกใด (ตารางที่ 1) และใช้วิธีควบคุมที่ตรงกับคำอธิบายทางเลือกนั้น ผู้วิจัยใช้แบบจำลองเดิมโดยไม่ปรับใหม่ เพราะ สิ่ง ที่ ทบทวน คือ การ ตรวจ สอบ ไม่ใช่ แบบจำลอง ตารางที่ 2 สรุปงานวิเคราะห์ทั้งสี่งาน

3.2 ชุดข้อมูล

ข้อมูล ทั้ง สาม ชุด เผย แพร่ สาธารณะ บน Metabo-Lights [14] MTBLS242 เป็นข้อมูล ^{1}H-NMR จาก ซี รัม ของ กลุ่ม ผู้ ป่วย ผ่าตัด ลด น้ำ หนัก มี เม แทบ อไลต์ที่วัดปริมาณได้ 21 ชนิด [15, 16] ใช้ในกรณีที่ 1, 2 และ 4 MTBLS1 เป็นข้อมูล ^{1}H-NMR จาก ปัสสาวะ ของ ผู้ ป่วย เบา หวาน ชนิด ที่ 2 และ กลุ่ม ควบคุม [17] ใช้ในกรณีที่ 3 และ MTBLS881 เป็นข้อมูล ^{1}H-NMR จาก ซี รัม ของ ผู้ ป่วย ผ่าตัด หัวใจ 47 คน ซึ่ง แต่ละ คน เก็บ ตัวอย่าง สอง ตำแหน่ง คือ Left Atrium (กำหนด เป็น ตำแหน่ง หลัก) และ Pulmonary Artery [18] ผู้ วิจัย ใช้ ชุด ข้อมูล นี้ เพื่อ ทำ ซ้ำ กรณี ที่ 1 เท่านั้น โดย กำหนด แผนการ วิเคราะห์ไว้ก่อนฝึกแบบจำลองใด ๆ กรณีที่ 2 และ 4 ใช้ ข้อมูล กลุ่ม เดียวกัน และ งาน จำแนก เดียวกัน (ตัวอย่าง ก่อน ผ่าตัด เทียบ กับ เดือน ที่ 12) แต่ ใช้ แบบ จำลอง ต่าง กัน (ตาราง ที่ 2) ทั้ง สอง กรณี จึง แสดงความล้มเหลวในการตีความสองแบบของงานจำแนกเดียวกัน ไม่ใช่การทำซ้ำที่เป็นอิสระต่อกัน

3.3 วิธีควบคุม (Controls)

3.3.1 คะแนนอ้างอิงที่ไม่ต้องฝึกแบบจำลอง (Learn-Nothing Scorer)

คะแนนที่คำนวณด้วยกฎตายตัวจากค่าตั้งต้นของผู้ป่วยแต่ละคนและทิศทางที่คาดหวังของสารบ่งชี้แต่ละตัว โดยไม่ต้องฝึกแบบจำลอง แบบจำลองที่ฝึกแล้วแต่ทำได้ไม่ดีกว่าคะแนนนี้ ไม่ได้แสดงอะไรเกินกว่าที่ความเชื่อมโยงระหว่างผลลัพธ์กับค่าตั้งต้นให้มา ผู้วิจัยรายงานผลต่าง (Gap) ระหว่างแบบจำลองกับคะแนนนี้ จากค่าทำนายของข้อมูลทดสอบที่รวมกันภายในแต่ละรอบของการตรวจสอบไขว้ พร้อมช่วงความเชื่อมั่น 95% จากการสุ่มซ้ำระดับบุคคล (Subject Bootstrap) เนื่องจากการรวมค่าทำนาย ผลต่างนี้จึงไม่เท่ากับผลต่างของค่า AP เฉลี่ยราย Fold พอดี

3.3.2 Pairing-Destroyed Null

ผู้วิจัยสลับว่าตัวอย่างติดตามผลเป็นของผู้ป่วยคนใด แล้วคำนวณผลลัพธ์ใหม่ วิธีนี้คงความเชื่อมโยงไว้แต่ตัดการตอบสนองรายบุคคลที่แท้จริงออก การสลับยังทำลายสหสัมพันธ์เชิงบวกระหว่างการวัดสองครั้งของผู้ป่วยคนเดียวกัน Null นี้จึงมีความเชื่อมโยง*มากกว่า*ข้อมูลจริง และอาจให้ Lift สูงกว่าค่าที่สังเกตได้แม้มีการตอบสนองจริงอยู่ จึงต้องอ่านผลในทิศทางเดียว คือถ้าแบบจำลองผ่าน Null นี้ได้ แสดงว่ามีสิ่งที่มากกว่าการถดถอยเข้าหาค่าเฉลี่ย ถ้าไม่ผ่าน แสดงเพียงว่ายังไม่มีหลักฐานของสิ่งที่มากกว่านั้น

3.3.3 Joint Residualisation

ภายในแต่ละ Fold ของข้อมูลฝึก ผู้วิจัยถดถอยการเปลี่ยนแปลงของสารบ่งชี้แต่ละตัว บนค่าตั้งต้นของสารบ่งชี้ทุกตัว แล้วใช้ส่วนเหลือ (Residual)

ตารางที่ 2 งานวิเคราะห์ทั้งสี่งานที่ทบทวน (AP = Average Precision ชุดข้อมูลของกรณีที่ 1 มีหนึ่งตัวอย่างต่อผู้ป่วย Stratified CV จึงแบ่งตามผู้ป่วยไปด้วย ในกรณีที่ 3 ข้อมูลว่าตัวอย่างใดเป็นของผู้ป่วยคนใดไม่ได้เผยแพร่ จึงต้องอนุมาน)

กรณี	ข้อมูล	ตัวอย่าง (บุคคล)	แบบจำลอง	การตรวจสอบ	ตัวชี้วัดหลัก
1	MTBLS242, ซีรัม	71 (71)	Sign-Constrained L2 Logistic	20×5 Stratified CV; สลับป้ายกำกับข้อมูลฝึกราย Fold และฝึกใหม่ (1,000 รอบ; ยังไม่ได้ตรวจการสอบเทียบ)	PR-AUC เฉลี่ยราย Fold
2	MTBLS242, ซีรัม	177 (106)	Monotone XGBoost	10×5 CV แบ่งตามผู้ป่วย; Recursive ROAR (เชิงสำรวจ)	PR-AUC เฉลี่ยจาก 50 Fold
3	MTBLS1, ปัสสาวะ	132 (40–42)	Monotone XGBoost	5-Fold CV แบ่งตามบุคคลที่อนุมาน; 20 Seed	PR-AUC เฉลี่ยราย Fold
4	MTBLS242, ซีรัม	177 (106)	XGBoost แบบไม่มีข้อจำกัด (แบบจำลองเดิม)	10×5 CV แบ่งตามผู้ป่วยเทียบกับแบบไม่แบ่ง (งานจำแนกเดียวกับกรณีที่ 2)	ROC-AUC เฉลี่ยราย Fold

กำหนด ป้าย กำกับ วิธี นี้ จัดการ ความ เชื่อม โยง เชิง เส้น ระหว่าง ค่า ตั้ง ต้น กับ การ เปลี่ยนแปลง แต่ ก็ เปลี่ยน ความ หมาย ของ “ผู้ ตอบ สนอง” เป็น ผู้ ที่ ดี ขึ้น มากกว่า ที่ ค่า ตั้ง ต้น ทำนาย ไว้ และ ตัด ความ สัมพันธ์ ทาง ชีววิทยา ที่แท้ จริง ระหว่าง การ เปลี่ยนแปลงกับค่าตั้งต้นออกไปพร้อมกับ Artefact ด้วย

3.3.4 ฟีเจอร์ Artefact สังเคราะห์

ฟีเจอร์ที่มีค่าเท่ากับค่าคงที่คูณป้ายกำกับแล้วบวกสัญญาณรบกวนแบบเกาส์เซียน ซึ่งไม่มีความหมายทางชีววิทยา ถูกส่งผ่านขั้นตอนการจัดอันดับด้วย SHAP และการตัดฟีเจอร์แบบเดียวกัน (สุ่ม 10 ครั้งต่อขนาดผล)

3.3.5 การตรวจ Metadata และที่มาของป้ายกำกับ

ผู้ วิจัย ทำตา ราง ไขว้ ระหว่าง ป้าย กำกับ กับ ทุก คอลัมน์ของ Metadata ที่เผยแพร่ อ่านโปรโตคอล การ เก็บ ตัวอย่าง ของ แต่ละ คลาส และ เขียน เป็น ประโยคเดียวว่าอะไรที่แยกสองคลาสออกจากกันในทางกายภาพ

3.4 วิธีสลับป้ายกำกับในการวิเคราะห์ข้อมูลจริง

ในทุก Fold ของการตรวจสอบไขว้แบบทำซ้ำ ผู้วิจัยสลับป้ายกำกับของข้อมูลฝึก เลือกค่า Penalty และฝึก แบบ จำลอง ใหม่ แล้ว ให้ คะแนน กับ ป้าย กำกับ ของข้อมูลทดสอบที่ไม่ได้สลับ สถิติที่ใช้คือค่า AP เฉลี่ยราย Fold วิธีสลับราย Fold นี้ใช้ในกรณีที่ 1 และการทำซ้ำบน MTBLS881 ผู้วิจัยยังไม่ได้ตรวจการสอบเทียบของวิธีนี้สำหรับแบบจำลองเหล่านี้ จึงถือว่าค่า p ที่ได้เป็นผลจากเครื่องมือวินิจฉัยที่ยังไม่ได้ตรวจการสอบเทียบ ไม่ใช่หลักฐานอิสระของความสัมพันธ์หรือของการตรวจสอบที่สำเร็จ ข้อสรุปในบทความนี้ไม่ได้ขึ้นกับค่าที่แน่นอนของค่า p เหล่านี้

3.5 การจำลอง (Simulation)

เพื่อ ดู ว่า เมื่อ ใด ที่ การ ทดสอบ เรียง สับ เปลี่ยน ถูก หลอก โดย ผลลัพธ์ ที่ คำนวณ จาก การ เปลี่ยนแปลง ผู้วิจัย จำลองกลุ่มตัวอย่างที่มีสารบ่งชี้ผลลัพธ์ 11 ตัว โดยกำหนดให้ระดับแฝงที่คงอยู่ของสารบ่งชี้มีสหสัมพันธ์ระหว่างกันเท่ากับ 0.3 (ค่าตั้งต้นที่วัดได้จึงมีสหสัมพันธ์ระหว่างกันเท่ากับ 0.3r) และมีฟีเจอร์เสริม 10 ตัว สารบ่งชี้แต่ละตัววัดที่ค่าตั้งต้นและค่าติดตามผลด้วยความเที่ยง (Reliability) r ซึ่งคือสัดส่วนความแปรปรวนที่คงอยู่ระหว่างการวัดสองครั้ง และค่าติดตามผลอาจมีการตอบสนองรายบุคคลที่พยากรณ์ได้ขนาด γ โดยเมื่อ $\gamma = 0$ จะไม่มีการตอบสนองที่พยากรณ์ได้ ผลลัพธ์คือ “สารบ่งชี้อย่างน้อย 6 ใน 11 ตัวเปลี่ยนไปในทิศทางที่

คาดหวัง” แบบจำลองคือ Ridge Regression บนฟีเจอร์ค่าตั้งต้น 21 ตัว ให้คะแนนด้วย Average Precision ใน 5-Fold CV ผู้วิจัยปรับ $n \in \{50, 100, 200, 500\}$, $r \in \{0.25, 0.5, 0.75\}$ และ $\gamma \in \{0, 0.25, 0.5\}$ โดยจำลอง 1,000 ชุดข้อมูลต่อเงื่อนไข ค่า $r = 0.25$ ให้สหสัมพันธ์ระหว่างค่าตั้งต้นกับการเปลี่ยนแปลงเท่ากับ -0.62 ตามที่พบใน MTBLS242 แต่ละชุดข้อมูลถูกทดสอบสี่วิธีที่ $\alpha = 0.05$ ด้วย Null 200 รอบ และฝึกแบบจำลองใหม่ทุกรอบ ได้แก่ การสลับป้ายกำกับของผลลัพธ์ การเปลี่ยนแปลงดิบ Pairing-Destroyed Null และ Residualisation รายสารบ่งชี้ (Per-Marker) กับแบบร่วม (Joint) ตามด้วยการสลับป้ายกำกับ กลุ่มผลลัพธ์ดิบ สลับป้ายกำกับทั้งชุดก่อนการตรวจสอบไขว้ ส่วนกลุ่ม Residualisation ใช้ป้ายกำกับเฉพาะของแต่ละ Fold และสลับป้ายกำกับของข้อมูลฝึกภายในแต่ละ Fold โดยคงป้ายกำกับของข้อมูลทดสอบไว้ การจำลองนี้ไม่ได้ยืนยันการสอบเทียบของวิธีที่ใช้ในการวิเคราะห์ข้อมูลจริง

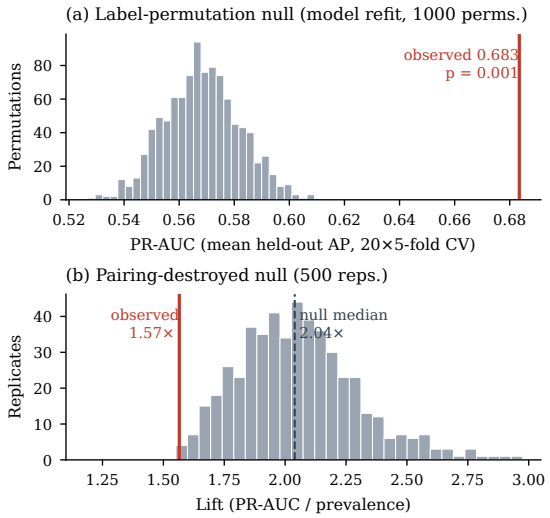
4. ผลการดำเนินงาน

4.1 กรณีที่ 1: ผลลัพธ์ที่ทำนายตัวเอง

สิ่งที่ผู้วิจัยเชื่อ โปรไฟล์ซีรัมก่อนผ่าตัดสามารถบอกได้ว่าผู้ป่วยคนใดใน 71 คน จะมีสารบ่งชี้ดีขึ้นอย่างน้อย 9 ใน 11 ตัวเมื่อครบ 12 เดือนหลังผ่าตัด

เหตุใดการตรวจสอบจึงผ่าน ค่าตั้งต้น x_0 ของสารบ่งชี้แต่ละตัวเป็นทั้งฟีเจอร์และเป็นพจน์หนึ่งในการเปลี่ยนแปลง $\Delta = x_{12} - x_0$ ในข้อมูลของผู้วิจัย ค่ามัธยฐานของสหสัมพันธ์ระหว่างค่าตั้งต้นกับการเปลี่ยนแปลงเท่ากับ -0.62 ฟีเจอร์ค่าตั้งต้นกับป้ายกำกับที่คำนวณจากการเปลี่ยนแปลงจึงไม่เป็นอิสระต่อกัน และเครื่องมือวินิจฉัยด้วยการสลับป้ายกำกับให้ค่า $p = 0.001$ ผลนี้ไม่ได้แสดงว่าแบบจำลองเรียนรู้อะไรเกี่ยวกับผู้ที่ตอบสนองต่อการผ่าตัด

สิ่งที่พบ คะแนนอ้างอิงได้ PR-AUC 0.709 สูงกว่าแบบจำลองที่ได้ 0.683 ภายใต้ Pairing-Destroyed Null ข้อมูลที่สลับแล้วให้ค่ามัธยฐานของ Lift เหนือความชุกเท่ากับ 2.04 เท่า เมื่อใช้คะแนนอ้างอิงจัดอันดับ และ 1.99 เท่า เมื่อฝึกแบบจำลองเต็มใหม่ทุกครั้งที่สลับ ขณะที่แบบจำลองได้ 1.57 เท่า (รูปที่ 1) จึงไม่มีหลักฐานของสิ่งที่มากกว่าการถดถอยเข้าหาค่าเฉลี่ย



รูปที่ 1 กรณีที่ 1 การออกแบบเดิม (a) เครื่องมือวินิจฉัยด้วยการสลับป้ายกำกับแบบเดิม (สลับป้ายกำกับข้อมูลฝึกภายในแต่ละ Fold และฝึกแบบจำลองใหม่ ยังไม่ได้ตรวจการสอบเทียบ) ซึ่งให้ค่า p = 0.001 (b) Pairing-Destroyed Null ของ Lift ที่คำนวณด้วยคะแนนอ้างอิง (มัธยฐาน 2.04 เท่า หากฝึกแบบจำลองเต็มใหม่ทุกครั้งได้มัธยฐาน 1.99 เท่า) แบบจำลองไม่ผ่าน Null นี้ Null นี้เป็นแบบอนุรักษ์ การไม่ผ่านจึงหมายความเพียงว่ายังไม่มีหลักฐานของการตอบสนอง ที่มากกว่าการถดถอยเข้าหาค่าเฉลี่ย ไม่ได้หมายความว่าไม่มีการตอบสนองนั้น

ต่อมา ผู้วิจัยจัดการความเชื่อมโยงเชิงเส้นระหว่างค่าตั้งต้นกับการเปลี่ยนแปลงด้วย Joint Residualisation การออกแบบนี้มีการเปลี่ยนแปลงสามอย่างที่สำคัญต่อการอ่านตัวเลข คือ เกณฑ์ผู้ตอบสนองเปลี่ยนเป็นอย่างน้อย 6 ใน 11 ตัว สารสามชนิดที่ยังไม่ทราบแหล่งที่มาแน่ชัดจากกรณีที่ 2 ถูกตัดออก (เหลือฟีเจอร์ 18 ตัวจาก 21 ตัว) และความชุกเพิ่มจาก 0.437 เป็น 0.521 ค่า PR-AUC จึงเทียบกับการออกแบบเดิมโดยตรงไม่ได้ ภายใต้การออกแบบนี้ แบบจำลองได้ PR-AUC 0.554 และคะแนนอ้างอิงได้ 0.589 (ค่าเฉลี่ย AP รายFold) ผลต่างจากค่าทำนายที่รวมกันเท่ากับ -0.037 ช่วงความเชื่อมั่น 95% จาก Subject Bootstrap คือ $[-0.111, +0.037]$ จึงไม่พบหลักฐานว่าแบบจำลองดีกว่าคะแนนอ้างอิงและด้วยจำนวน 71 คน ช่วงความเชื่อมั่นยังไม่ตัดความเป็นไปได้ที่แบบจำลองจะมีสมรรถนะสูงกว่าคะแนนอ้างอิงเล็กน้อย

4.2 ผลการจำลอง: ข้อมูลมากขึ้น การปฏิเสธยิ่งมั่นใจขึ้น

ผลการจำลองสองข้อทำให้ผู้วิจัยประหลาดใจมากกว่าข้อผิดพลาดเดิม (รูปที่ 2) ข้อแรก เมื่อไม่มีการตอบสนองที่พยากรณ์ได้และ $r = 0.25$ การสลับป้ายกำกับของผลลัพธ์การเปลี่ยนแปลงดิบปฏิเสธสมมติฐานความเป็นอิสระ ในร้อยละ 26 ของชุดข้อมูลเมื่อ $n = 50$ และร้อยละ 100 เมื่อ $n = 500$ การปฏิเสธแต่ละครั้งถูกต้องในเรื่องความเป็นอิสระ แต่ผิดหากใช้เป็นหลักฐานของการพยากรณ์ กลุ่มตัวอย่างที่ใหญ่ขึ้นช่วยประมาณความเชื่อมโยงได้แม่นยำขึ้น แต่ไม่ได้ทำให้ความเชื่อมโยงหายไป ข้อสอง Residualisation รายสารบ่งชี้ ซึ่งถดถอยการเปลี่ยนแปลงของสารบ่งชี้แต่ละตัวบนค่าตั้งต้นของตัวเองเท่านั้น และเป็นวิธีแก้ที่ใช้ในการวิเคราะห์ฉบับแก้ไขของผู้วิจัย ยังปฏิเสธในร้อยละ 8–29 ของชุดข้อมูลจำลองที่ไม่มีการตอบสนองรายบุคคลที่พยากรณ์ได้ในเงื่อนไขต่าง ๆ เพราะสารบ่งชี้ที่สัมพันธ์กันพาข้อมูลค่าตั้งต้นของกันและกันมาด้วย Joint Residualisation ลดอัตรานี้เหลือร้อยละ 5–8 ซึ่งสูงกว่าระดับที่กำหนดไว้ร้อยละ 5 เล็กน้อย วิธีแก้ไขก็เป็นการตรวจสอบอย่างหนึ่ง และต้องได้รับการตรวจสอบเช่นกัน

4.3 การทำซ้ำในกลุ่มตัวอย่างที่สอง

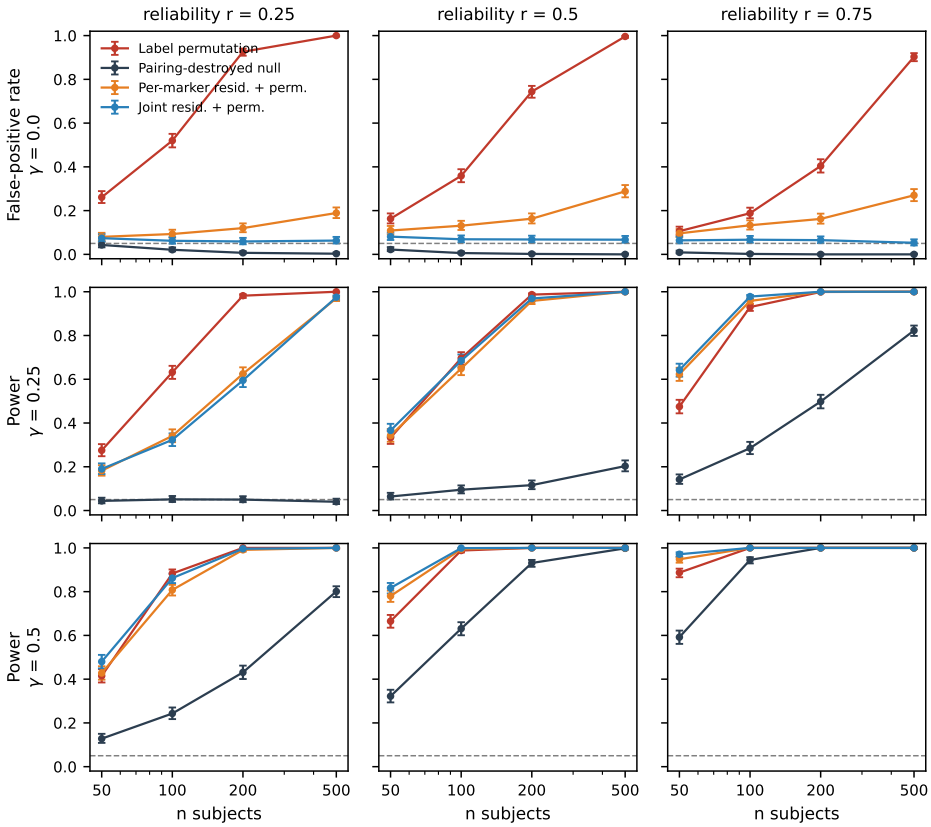
ใน MTBLS881 เครื่องมือวินิจฉัยด้วยการสลับป้ายกำกับให้ค่า $p = 0.007$ ที่ทั้งสองตำแหน่งสำหรับผลลัพธ์การเปลี่ยนแปลงดิบ ทั้งสองตำแหน่งไม่แสดงว่าแบบจำลองดีกว่าคะแนนอ้างอิง ช่วงความเชื่อมั่น 95% ของผลต่างระหว่างแบบจำลองกับคะแนนนี้ครอบคลุมศูนย์ทั้งสองตำแหน่ง (–0.037 [–0.231, +0.118] ที่ Left Atrium และ +0.013 [–0.111, +0.154] ที่ Pulmonary Artery) ทั้งสองตำแหน่งมาจากผู้ป่วยกลุ่มเดียวกัน จึงเป็นการสังเกตที่สัมพันธ์กัน ไม่ใช่การทำซ้ำสองครั้ง และค่า p มาจากวิธีสลับราย Fold แบบเดียวกันที่ยังไม่ได้ตรวจการสอบเทียบ ในที่นี้ใช้กับแบบจำลองที่ไม่มีข้อจำกัด ส่วนคำถามว่าหลัง Joint Residualisation ยังมีสัญญาณจริงเหลืออยู่หรือไม่ ผลจากผู้ป่วย 47 คนในชุดข้อมูลนี้ยังไม่ให้ข้อสรุปที่ชัดเจน

4.4 กรณีที่ 2: คำอธิบายที่ซื่อตรงต่อสิ่งที่ผิด

สิ่งที่ผู้วิจัยเชื่อ ตัวจำแนกที่แยกตัวอย่างก่อนผ่าตัดกับเดือนที่ 12 (PR-AUC 0.973, CV แบ่งตามผู้ป่วย) พึ่งพาเมแทบอไลต์ที่บอกว่าการผ่าตัดเปลี่ยนแปลงเมแทบอลิซึมอย่างไร และ ROAR ยืนยันว่าเป็นสารใดบ้าง

เหตุใดการตรวจสอบจึงผ่าน การตัดฟีเจอร์ตามอันดับจาก SHAP ทีละตัวและฝึกใหม่ทำให้แบบจำลองแย่ลงมากกว่าการตัดฟีเจอร์แบบสุ่มตั้งแต่การตัดครั้งที่สามเป็นต้นไป ผลการตัดฟีเจอร์เชิงสำรวจนี้ชี้ว่าแบบจำลองพึ่งพาฟีเจอร์เหล่านั้น แต่ฟีเจอร์ห้าตัวแรกที่ถูกตัดมี Dimethyl Sulfone, Isopropanol และ Methanol อยู่ด้วย Isopropanol ใช้ทำความสะอาดผิวหนังและการจัดการระหว่างเก็บตัวอย่างอาจทำให้สารจากภายนอกปนเข้ามาในตัวอย่างได้ [10, 11] แหล่งอ้างอิงเหล่านี้อธิบายความเสี่ยงทั่วไป ไม่ได้ยืนยันการปนเปื้อนในข้อมูลกลุ่มนี้ ส่วน Dimethyl Sulfone เป็นเมแทบอไลต์ปกติในพลาสมา ซึ่งมาจากอาหาร แบคทีเรียในลำไส้ และเมแทบอลิซึมของกำมะถันในร่างกาย [19] ซึ่งล้วนอาจต่างกันระหว่างก่อนและหลังผ่าตัด ผู้วิจัยจึงถือว่าสารทั้งสามเป็นสารที่*ยังไม่ทราบแหล่งที่มาแน่ชัด* อาจสะท้อนชีววิทยา การจัดการตัวอย่าง หรือทั้งสองอย่าง และการมาจากภายนอกร่างกายก็ไม่ได้หมายความว่าเป็นการปนเปื้อนระหว่างการจัดการตัวอย่างเสมอไป ข้อมูลที่เผยแพร่ไม่สามารถตัดสินเรื่องนี้ได้ และข้อโต้แย้งต่อไปนี้ไม่ได้ขึ้นกับเรื่องนี้

สิ่งที่พบ การตัดสารทั้งสามนี้ให้ PR-AUC 0.954 การตัดเมแทบอไลต์ที่เป็นที่ยอมรับสามชนิดให้ 0.959 การตัดทั้งสองแบบทำให้สมรรถนะต่ำกว่าการตัดแบบสุ่มเกือบทั้งหมด ผลต่างที่สังเกตได้คือ 0.0056 เทียบกับส่วนเบี่ยงเบนมาตรฐานระหว่าง Fold ประมาณ 0.03 และผู้วิจัยไม่ได้ทำการทดสอบความเทียบเท่า (Equivalence Test) อย่างเป็นทางการ กล่าวอีกนัยหนึ่ง ROAR ไม่ได้ส่งสัญญาณใดว่าสองกลุ่มนี้มีแหล่งที่มาต่างกันสำหรับฟีเจอร์ Artefact สังเคราะห์ที่มีขนาดผลใกล้เคียงกับ Dimethyl Sulfone SHAP จัดให้เป็นอันดับหนึ่งใน 6 จาก 10 ครั้ง และอันดับสองในครั้งที่เหลือ และค่ามัธยฐานของสมรรถนะที่ลดลงเมื่อตัดฟีเจอร์นี้เพียงตัวเดียวสูงกว่าเมแทบอไลต์จริงทุกตัว ข้อควรระวังคือ การจัดอันดับด้วย SHAP



รูปที่ 2 อัตราการปฏิเสธจากการจำลองเทียบกับจำนวนบุคคล (1,000 ชุดข้อมูลต่อจุด แถบความคลาดเคลื่อนคือช่วงความเชื่อมั่น 95% แบบ Wilson ของสัดส่วนการปฏิเสธ) แถวแสดงขนาดของการตอบสนองที่พยากรณ์ได้ (γ = 0, 0.25 และ 0.5) คอลัมน์แสดงความเที่ยงของการวัด r เมื่อ γ = 0 ไม่มีการตอบสนองรายบุคคลที่พยากรณ์ได้ การปฏิเสธทุกครั้งในแถวบน (แกนระบุว่า False-positive rate) จึงเป็นสัญญาณเท็จของความสามารถในการพยากรณ์ แม้จะปฏิเสธความเป็นอิสระได้ถูกต้องก็ตาม สำหรับผลลัพธ์การเปลี่ยนแปลงดิบ การสลับป้ายกำกับทั้งชุดเพิ่มเข้าใกล้ร้อยละ 100 เมื่อ n เพิ่มขึ้น Residualisation รายสารบ่งชี้ก็เพิ่มขึ้นเช่นกัน ส่วน Joint Residualisation คงอยู่ที่ร้อยละ 5–8 แถวล่างแสดงอำนาจการทดสอบเมื่อมีการตอบสนองที่พยากรณ์ได้ เส้นประคือ α = 0.05

คำนวณจากตัวอย่างทั้ง 177 ตัว รวมถึงตัวอย่างที่ใช้ประเมินผลภายหลัง การตัดฟีเจอร์ตามอันดับจึงมีความเอนเอียงจากการคัดเลือก (Selection Bias) ที่ไม่ทราบขนาด [20] ผู้วิจัยจึงถือว่าการเปรียบเทียบ ROAR เป็นผลเชิงสำรวจ และฟีเจอร์สังเคราะห์สนับสนุนประเด็นเชิงแนวคิดได้โดยไม่ต้องพึ่งการเปรียบเทียบเหล่านั้น

บทเรียน การทดสอบความซื่อตรงของคำอธิบายต่อแบบจำลอง (Faithfulness Test) ตรวจว่าฟีเจอร์ที่คำอธิบายให้ความสำคัญสอดคล้องกับฟีเจอร์ที่มีผลต่อการทำนายของแบบจำลองหรือไม่ ไม่ได้รับรองความถูกต้องของแบบจำลองโดยรวม การทดสอบแบบตัดฟีเจอร์ วัดว่าฟีเจอร์มีสัญญาณที่ไม่ซ้ำกับฟีเจอร์อื่นมากเพียงใด ไม่ว่าสัญญาณนั้นจะมาจากไหน การทดสอบนี้ซื่อตรงต่อแบบจำลอง และแบบจำลองก็ซื่อตรงต่อสิ่งใดก็ตามที่แยกคลาสออกจากกัน [21, 22] ROAR จึงตัดสินแหล่งที่มาไม่ได้ ไม่สามารถบอกได้ว่าฟีเจอร์อันดับต้นสะท้อนชีววิทยา การจัดการตัวอย่าง หรือทั้งสองอย่าง และสำหรับสารสามชนิดนี้ คำถามดังกล่าวยังคงเปิดอยู่

4.5 กรณีที่ 3: ข้อมูลกลุ่มเดียวที่แท้จริงคือสองการศึกษา

สิ่งที่ผู้วิจัยเชื่อ สเปกตรัม NMR ของปัสสาวะแยกผู้ป่วยเบาหวานชนิดที่ 2 ออกจากกลุ่มควบคุมได้ด้วย PR-AUC 0.976 ภายใต้ CV ที่แบ่งตามบุคคล

เหตุใดการตรวจสอบจึงผ่าน การแบ่งตามบุคคลป้องกันไม่ให้แบบจำลองจำบุคคลที่เคยเห็น

แล้วได้ แต่ไม่สามารถตรวจพบความแตกต่างที่สมาชิกทุกคนในคลาสหนึ่งมีร่วมกัน

สิ่งที่พบ ค่า 0.976 มาจาก Random Seed เดียว เมื่อใช้ 20 Seed ค่าเฉลี่ยคือ 0.911 (ช่วง 0.845–0.975) จากนั้นผู้วิจัยทำตารางไขว้ระหว่างป้ายกำกับกับคอลัมน์ Metadata ที่เผยแพร่ทั้ง 64 คอลัมน์ พบว่า 56 คอลัมน์มีค่าคงที่ และนอกจากรหัสประจำตัวอย่างแล้ว มีเพียงเพศและป้ายกำกับที่มีค่าแปรผัน ไม่มีคอลัมน์ใดบันทึกวันที่ Batch หรือลำดับการวัด อย่างไรก็ตาม โปรโตคอลที่เผยแพร่ระบุว่าข้อมูลมาจากสองการศึกษา คือ อาสาสมัคร 12 คน อายุ 18–55 ปี เก็บตัวอย่าง 7 ช่วงเวลาที่กำหนด และผู้ป่วยอายุ 30–65 ปีที่มีดัชนีมวลกายสูงกว่า เก็บตัวอย่าง 1–3 ครั้ง ชื่อตัวอย่างของกลุ่มควบคุมทุกตัวขึ้นต้นด้วย `ADG19007u` และของผู้ป่วยทุกตัวขึ้นต้นด้วย `ADG10003u` การเป็นสมาชิกของกลุ่มการศึกษา รวมถึงตารางการเก็บตัวอย่าง และความแตกต่างใด ๆ ในวิธีเก็บและเก็บรักษาปัสสาวะของสองการศึกษา จึงปะปนกับป้ายกำกับอย่างสมบูรณ์ อายุและดัชนีมวลกายมีเกณฑ์คัดเข้าที่ต่างกันแต่ซ้อนทับกัน จึงเป็นตัวแปรกวนที่เป็นไปได้ด้วย และไม่มีการบันทึกค่าเหล่านี้รายตัวอย่าง

ข้อจำกัดเชิงวิธีของการทบทวนครั้งนี้ควรกล่าวไว้ ณ ที่นี้ ข้อมูลว่าตัวอย่างใดเป็นของผู้ป่วยคนใดไม่ได้เผยแพร่ ผู้วิจัยจึงจัดกลุ่มตัวอย่างของผู้ป่วยด้วยวิธีอนุมานจากลำดับหมายเลข ซึ่งรวมผู้ป่วยต่างคนกันอย่างน้อยสามคู่ไว้ในกลุ่มเดียวกัน ซึ่งเป็นแบบอนุรักษ์สำหรับคู่เหล่านั้น แต่ผู้วิจัยไม่สามารถตัดความเป็นไปได้ว่าวิธีนี้แยกตัวอย่างของผู้ป่วยคนเดียวกันไปอยู่คนละกลุ่ม การจัดกลุ่มมีผลต่อคะแนนจริง ด้วย 20 Seed เดียวกัน CV ที่แบ่งตามบุคคลได้ 0.911 (0.906 เมื่อใช้การจัดกลุ่มอีกแบบที่สอดคล้องกับโปรโตคอล) และ CV ที่ไม่แบ่งตามบุคคลได้ 0.969 อย่างไรก็ตาม ปัญหาโปรโตคอลไม่ได้ขึ้นกับการจัดกลุ่ม เพราะเป็นคุณสมบัติของการออกแบบการศึกษา และไม่มีวิธีแบ่ง Fold ใดขจัดปัญหานี้ได้

บทเรียน ตัวจำแนกอาจเรียนรู้โรคเบาหวาน โปรโตคอลการเก็บตัวอย่าง หรือทั้งสองอย่าง ข้อมูลนี้ไม่สามารถบอกได้ว่าเป็นแบบใด เพราะแต่ละโปรโตคอลมีเพียงคลาสเดียว [8] ข้อมูลชุดนี้ไม่สามารถแยกอิทธิพลของโรคออกจากอิทธิพลของโปรโตคอลการเก็บตัวอย่าง จึงยังสรุปไม่ได้ว่าสมรรถนะของแบบจำลองสะท้อนความแตกต่างของโรคจริงหรือไม่

4.6 กรณีที่ 4: ป้ายกำกับที่ถูกตั้งชื่อตามสิ่งอื่น

สิ่งที่ผู้วิจัยเชื่อ NMR ของซีรัมแยกคนอ้วนออกจากคนที่ไม่อ้วนได้ด้วย ROC-AUC 0.973 ซึ่งเป็น AUC ของเส้นโค้ง ROC เฉลี่ยจากการแบ่ง Stratified 5-Fold เพียงครั้งเดียว (0.974 เมื่อรันซ้ำ)

เหตุใดการตรวจสอบจึงผ่าน เมื่อทำการประเมินซ้ำ 10 ครั้งด้วยแบบจำลองเดิม CV ที่แบ่งตามผู้ป่วยและที่ไม่แบ่งต่างได้ค่าเฉลี่ย ROC-AUC ราย Fold เท่ากับ 0.965 (เป็นตัวสรุปคนละแบบกับ AUC ของเส้นโค้งเฉลี่ย การแบ่งที่รันซ้ำให้ค่าเฉลี่ย AUC ราย Fold เท่ากับ 0.976) แม้ใน CV ที่ไม่แบ่งตามผู้ป่วย ร้อยละ 65 ของตัวอย่างทดสอบ จะมีตัวอย่างอีกครั้งของผู้ป่วยคนเดียวกันอยู่ในข้อมูลฝึก การกำจัดการรั่วไหลนี้ไม่ได้ทำให้คะแนนลดลง และความสอดคล้องนี้ดูน่าเชื่อถือ

สิ่งที่พบ คลาส “ไม่อ้วน” คือการเก็บตัวอย่างเดือนที่ 12 หลังผ่าตัดของผู้ป่วยกลุ่มเดียวกัน จากผู้ป่วย 106 คน มี 71 คนที่อยู่ในทั้งสองคลาส และมีตัวอย่างรวมกันร้อยละ 80 ของตัวอย่างทั้งหมด Metadata ไม่ได้บันทึกดัชนีมวลกาย จึงไม่สามารถตรวจได้ว่าผู้ป่วยเดือนที่ 12 คนใดไม่อ้วนแล้ว คะแนนนี้สะท้อนสิ่งใดก็ตามที่ต่างกันระหว่างคนคนหนึ่งก่อนผ่าตัดลดน้ำหนัก กับคนเดิมหนึ่งปีต่อมา ทั้งน้ำหนักที่ลดลง และอาจรวมถึงอาหาร อาหารเสริม และยาหลังผ่าตัด รวมทั้งระยะเวลาเก็บรักษาตัวอย่างที่ต่างกันหนึ่งปี ข้อมูลนี้ไม่สามารถระบุได้ว่าคะแนนนี้มาจากภาวะอ้วน

บทเรียน ชื่อที่ถูกต้องคือ “การจำแนกก่อนและหลังการผ่าตัด”

4.7 รูปแบบร่วมของทั้งสี่กรณี

ในทุกกรณี การตรวจสอบชี้ว่าข้อมูลมีโครงสร้างที่ใช้พยากรณ์ได้ โดยมีข้อควรระวังเรื่องวิธีสลับป้ายกำกับและการเปรียบเทียบ ROAR เชิงสำรวจตามที่กล่าวไว้แล้ว สิ่งที่การตรวจสอบยืนยันไม่ได้คือโครงสร้างนั้นมาจากไหน ไม่ว่าจะมาจากการคำนวณผลลัพธ์ จากสารที่ยังไม่ทราบแหล่งที่มาจากโปรโตคอลการเก็บตัวอย่าง หรือจากการผ่าตัด คำอธิบายทางเลือกเหล่านี้ผ่านการตรวจสอบได้ง่ายพอ ๆ กับคำอธิบายทางชีววิทยาที่ผู้วิจัยคิด

ไว้ การผ่านการตรวจสอบจึงแยกคำอธิบายเหล่านี้ออกจากกันไม่ได้ มีนิสัยสามอย่างที่ทำให้มองข้ามปัญหานี้ได้ง่าย

รายงานการตรวจสอบ แต่ไม่รายงานคำอธิบายทางเลือก ส่วนวิธีการวิจัยมักระบุการตรวจสอบที่ทำ แต่แทบไม่ระบุคำอธิบายทางเลือกที่การตรวจสอบนั้นตั้งใจตรวจ เมื่อระบุการตรวจสอบไว้แล้ว ผู้อ่านก็มักเข้าใจว่าเป็นใบรับรองความถูกต้องโดยรวม ทั้งที่การตรวจสอบนั้นตรวจรูปแบบความล้มเหลวเพียงแบบเดียว

เชื่อตัวเลขที่ดูดีกว่า ค่า p ที่ต่ำกว่า ขนาดตัวอย่างที่ใหญ่กว่า หรือ AUC ที่ใกล้ 1 ให้ความรู้สึกว่าเป็นหลักฐานที่หนักแน่นกว่า กรณีที่ 1 และการจำลองแสดงสถานการณ์ที่ข้อมูลมากขึ้นทำให้การปฏิเสธมั่นใจขึ้น แต่ไม่ได้ให้ข้อมูลมากขึ้น และกรณีที่ 3 แสดงคะแนนสูงที่ขึ้นกับ Seed ซึ่งตั้งอยู่บนตัวแปรกวนจากการออกแบบการศึกษา ในกลุ่มตัวอย่างขนาดเล็ก คะแนนที่ใกล้ 1 เป็นเหตุผลให้มองหาตัวแทน (Proxy) ไม่ใช่เหตุผลให้หยุดตรวจ

ตรวจแบบจำลอง แต่ไม่ตรวจป้ายกำกับ การตรวจสอบทั้งหมดของผู้วิจัยถือว่าป้ายกำกับถูกต้องอยู่แล้ว ความล้มเหลวสองในสี่กรณีอยู่ที่ตัวป้ายกำกับเอง (กรณีที่ 1 และ 4) และอีกกรณีหนึ่ง (กรณีที่ 3) อยู่ที่วิธีเก็บตัวอย่างของแต่ละคลาส การตรวจสอบแบบจำลองไม่ว่ามากเพียงใดก็เข้าไม่ถึงปัญหาที่อยู่ก่อนถึงแบบจำลอง

5. สรุปผลและแนวทางในอนาคต

5.1 สรุปผลการวิจัย

งานวิเคราะห์ทั้งสี่งานของผู้วิจัยให้ผลที่ผู้วิจัยเคยถือว่าผ่านการตรวจสอบความถูกต้องแล้ว แต่ในทุกงาน การตีความทางชีววิทยาที่ผู้วิจัยให้กับผลนั้นไม่มีหลักฐานรองรับหรือไม่สามารถระบุได้ แบบจำลองพยากรณ์ผู้ตอบสนองไม่แสดงหลักฐานว่าดีกว่าคะแนนอ้างอิงที่ $n = 71$ ซึ่งเป็นการไม่มีหลักฐาน ไม่ใช่หลักฐานว่าพยากรณ์ไม่ได้ ผล ROAR เชิงสำรวจชี้ว่าแบบจำลองพึ่งพาฟีเจอร์ใด แต่ไม่ได้บอกว่าฟีเจอร์เหล่านั้นมาจากไหน สำหรับตัวจำแนกเบาหวาน ข้อมูลนี้ไม่สามารถแยกได้ว่าสมรรถนะเกิดจากโรค หรือจากโปรโตคอลการเก็บตัวอย่าง และตัวจำแนกโรคอ้วนแท้จริงคือตัวจำแนกก่อนและหลังการผ่าตัด การตรวจสอบที่ผ่านแสดงเพียงว่าได้ตรวจรูปแบบความล้มเหลวหนึ่งแบบ ภายใต้สมมติฐานของการตรวจสอบนั้น ไม่ได้ยืนยันว่าการตีความถูกต้อง

ข้อสรุปเหล่านี้มีข้อจำกัด ผู้วิจัยทบทวนเฉพาะงานของตนเองบนข้อมูลสาธารณะขนาดเล็กสามชุด ซึ่งเลือกมาเพราะสามารถตรวจสอบปัญหาได้จากไฟล์ที่เผยแพร่ และไม่ได้กล่าวอ้างว่าความล้มเหลวเหล่านี้พบบ่อยเพียงใดในงานวิจัยที่ตีพิมพ์ ข้อค้นพบเกี่ยวข้องกับแนวปฏิบัติในการตรวจสอบความถูกต้อง และไม่ได้สนับสนุนหรือคัดค้านความรู้ทางชีววิทยาของโรคอ้วน การผ่าตัดลดน้ำหนัก หรือเบาหวาน ผู้วิจัยไม่ได้แสดงว่าตัวจำแนกใดใช้*เพียง* Artefact แต่แสดงว่าการตรวจสอบไม่สามารถตัด Artefact ออกได้ แหล่งที่มาของสารสามชนิดในกรณีที่ 2 ยังไม่ได้รับการยืนยัน ค่า p ในกรณีที่ 1 และการทำซ้ำมาจากวิธีสลับราย Fold ที่ยังไม่ได้ตรวจการสอบเทียบการจำลองใช้ข้อมูลแบบเกาส์เซียน แบบจำลองเชิงเส้น และเกณฑ์ผลลัพธ์แบบเดียว และ Joint Residualisation ที่การจำลองสนับสนุนก็ตัดความสัมพันธ์ที่แท้จริงระหว่างการเปลี่ยนแปลงกับค่าตั้งต้นออกด้วย การตรวจสอบที่กล่าวถึงมีประโยชน์เมื่อใช้ให้ตรงกับสมมติฐานและเป้าหมาย ประเด็นของบทความนี้คือ การผ่านการตรวจสอบเหล่านี้ยังไม่เพียงพอสำหรับการตีความทางชีววิทยา

5.2 แนวทางในอนาคต

สำหรับงานเมแทบอโลมิกส์ที่มีขนาดตัวอย่างเล็กในอนาคต รวมถึงงานของผู้วิจัยเอง ผู้วิจัยเสนอให้ระบุคำอธิบายทางเลือกของคะแนนหลักก่อนเลือกการทดสอบ และตั้งคำถามหกข้อต่อไปนี้ ซึ่งบทความคู่กันมีโค้ดอ้างอิงสำหรับแต่ละข้อ [1]

1) *ผลลัพธ์คำนวณจากฟีเจอร์หรือไม่* ถ้าใช่ การสลับป้ายกำกับไม่ใช่หลักฐานของการพยากรณ์ หากเป้าหมายคือการเปลี่ยนแปลงที่มากกว่าที่ค่าตั้งต้นทำนายไว้ ให้ถดถอยการเปลี่ยนแปลงบนค่าตั้งต้น*ทุกตัว*ภายในแต่ละ Fold ของข้อมูลฝึก แต่หากการเปลี่ยนแปลงที่ขึ้นกับค่าตั้งต้นเป็นสิ่งที่สนใจเอง วิธีนี้จะตัดสิ่งนั้นออก และคำถามนี้อาจต้องใช้การวัดค่าตั้งต้นซ้ำ หรือการออกแบบอื่นที่แยกความคลาดเคลื่อนของการวัดออกจากการตอบสนอง ไม่ว่ากรณีใด ให้รายงาน Pairing-Destroyed Null เป็นเครื่องมือวินิจฉัยทางเดียว

2) *ฝึกแบบจำลองใหม่ในทุกรอบของการสลับหรือไม่ และ ระบุ วิธี สลับ ไว้ หรือ ไม่* หาก ค่า สถิติ ที่สังเกตได้ต่ำกว่า Null ทั้งหมด ให้ตรวจวิธีสร้าง Null ขั้นตอนการให้คะแนน ข้อจำกัดของแบบจำลอง และวิธีฝึก ก่อนอ่านค่า *p*

3) *แบบ จำลอง ดี กว่า คะแนน อ้างอิง ที่ ไม่ ต้อง ฝึก แบบจำลองหรือไม่* ให้รายงานผลต่างพร้อมช่วงความเชื่อมั่นที่สุ่มซ้ำระดับบุคคล

4) *มี ฟีเจอร์ ใด ที่ อาจ มา จาก การ จัดการ ตัวอย่าง หรือจากยาหรือไม่* ให้รายงานผลทั้งแบบมีและไม่มี ฟีเจอร์ เหล่า นั้น และ ส่ง ฟีเจอร์ ที่ รู้ แน่ ว่า ไม่มี ความ หมาย ทาง ชีววิทยา ผ่าน ขั้น ตอน การ อธิบาย ฟีเจอร์

5) *มี คอลัมน์ Metadata หรือ โปรโตคอล การ เก็บ ตัวอย่าง ใด ที่สอดคล้องกับป้ายกำกับหรือไม่* ให้ ทำตารางไขว้ระหว่างป้ายกำกับกับทุกคอลัมน์ และอ่านว่าแต่ละคลาสเก็บตัวอย่างอย่างไร

6) *อะไร ที่ แยก สอง คลาส ออก จาก กัน ใน ทาง กายภาพ เมื่อ เขียน เป็น ประโยค เดียว* ถ้าประโยค นั้น ต่าง จาก ชื่อ บทความ ให้เปลี่ยน ชื่อ บทความ

คำถามเหล่านี้ใช้กับข้อมูลที่มีอยู่แล้วได้ แม้การแก้ปัญหาบางข้อที่พบอาจต้องใช้การวัดใหม่หรือการออกแบบการศึกษาที่ต่างออกไป สำหรับการทบทวนครั้งนี้ มีการวิเคราะห์สี่อย่างที่จะช่วยเสริมหลักฐาน ได้แก่ การรันการทดสอบในกรณีที่ 1 สำหรับผลลัพธ์การเปลี่ยนแปลงดิบซ้ำด้วยการสลับป้ายกำกับทั้งชุด เพื่อประเมินความไวของข้อสรุปต่อวิธีสลับป้ายกำกับ การประเมินอัตราการปฏิเสธของวิธีสลับราย Fold จากข้อมูลจำลองซ้ำภายใต้สมมติฐานว่างที่ต้องการทดสอบ เพื่อตรวจการสอบเทียบของวิธีนี้ (โดยแยกกรณีที่ไม่มีการตอบสนองที่พยากรณ์ได้ ออกจากกรณีที่ฟีเจอร์กับป้ายกำกับเป็นอิสระต่อกัน ซึ่งไม่ใช่เงื่อนไขเดียวกัน) การคำนวณอันดับ SHAP ของกรณีที่ 2 ภายในแต่ละ Fold ของข้อมูลฝึก และการทำกรณีที่ 4 ซ้ำในข้อมูลที่มีการบันทึกดัชนีมวลกายและมีกลุ่มควบคุมที่ไม่อ้วน

ข้อมูลและโค้ด

ชุดข้อมูล MTBLS242, MTBLS1 และ MTBLS881 เผยแพร่สาธารณะผ่าน MetaboLights [14] โค้ดการวิเคราะห์ การจำลอง และบันทึกตัวเลขทุกค่าที่รายงานพร้อมสคริปต์และ Random Seed สามารถขอได้จากผู้วิจัย

กิตติกรรมประกาศ

ผู้ วิจัย ขอ ขอบคุณ ที่ ปรึกษา ของ งาน วิจัย นี้ คือ ผศ.ดร. นนท์ คนึง สุข เกษม แห่ง คณะ เทคโนโลยี สารสนเทศ สถาบัน เทคโนโลยี พระจอมเกล้า เจ้าคุณ ทหาร ลาดกระบัง งาน วิจัย นี้ ไม่ ได้ รับ ทุน สนับสนุนเฉพาะ

เอกสารอ้างอิง

[1] Orrudee, C., & Shomwiwat, K. C. (2026). *Validated, yet wrong: Four ways small-n metabolomics machine learning passes standard checks* [Unpublished manuscript].

[2] Ojala, M., & Garriga, G. C. (2010). Permutation tests for studying classifier performance. *Journal of Machine Learning Research, 11*, 1833–1863.

[3] Hooker, S., Erhan, D., Kindermans, P.-J., & Kim, B. (2019). A benchmark for interpretability methods in deep neural networks. *Advances in Neural Information Processing Systems, 32*.

[4] Oldham, P. D. (1962). A note on the analysis of repeated measurements of the same subjects. *Journal of Chronic Diseases, 15*(10), 969–977. doi:10.1016/0021-9681(62)90116-9

[5] Barnett, A. G., van der Pols, J. C., & Dobson, A. J. (2005). Regression to the mean: What it is and how to deal with it. *International Journal of Epidemiology, 34*(1), 215–220. doi:10.1093/ije/dyh299

[6] Tu, Y.-K., & Gilthorpe, M. S. (2007). Revisiting the relation between change and initial value: A review and evaluation. *Statistics in Medicine, 26*(2), 443–457. doi:10.1002/sim.2538

[7] Archie, J. P. (1981). Mathematic coupling of data: A common source of er-

ror. *Annals of Surgery, 193*(3), 296–303. doi:10.1097/00000658-198103000-00008

[8] Leek, J. T., et al. (2010). Tackling the widespread and critical impact of batch effects in high-throughput data. *Nature Reviews Genetics, 11*(10), 733–739. doi:10.1038/nrg2825

[9] Han, W., & Li, L. (2022). Evaluating and minimizing batch effects in metabolomics. *Mass Spectrometry Reviews, 41*(3), 421–442. doi:10.1002/mas.21672

[10] Bernini, P., Bertini, I., Luchinat, C., Nincheri, P., Staderini, S., & Turano, P. (2011). Standard operating procedures for pre-analytical handling of blood and urine for metabolomic studies and biobanks. *Journal of Biomolecular NMR, 49*(3–4), 231–243. doi:10.1007/s10858-011-9489-1

[11] van der Sar, S. A., et al. (2015). Ethanol contamination of cerebrospinal fluid during standardized sampling and its effect on ^{1}H-NMR metabolomics. *Analytical and Bioanalytical Chemistry, 407*(16), 4835–4839. doi:10.1007/s00216-015-8663-9

[12] Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns, 4*(9), 100804. doi:10.1016/j.patter.2023.100804

[13] Collins, G. S., et al. (2024). TRIPOD+AI statement: Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ, 385*, e078378. doi:10.1136/bmj-2023-078378

[14] Haug, K., et al. (2020). MetaboLights: A resource evolving in response to the needs of its scientific community. *Nucleic Acids Research, 48*(D1), D440–D444. doi:10.1093/nar/gkz1019

[15] EMBL-EBI. (2017). *MetaboLights study MTBLS242: Metabolomic fingerprint of severe obesity is dynamically affected by bariatric surgery in a procedure-dependent manner* [Data set]. สืบค้นจาก `https://www.ebi.ac.uk/metabolights/MTBLS242`

[16] Gralka, E., Luchinat, C., Tenori, L., Ernst, B., Thurnheer, M., & Schultes, B. (2015). Metabolomic fingerprint of severe obesity is dynamically affected by bariatric surgery in a procedure-dependent manner. *The American Journal of Clinical Nutrition, 102*(6), 1313–1322. doi:10.3945/ajcn.115.110536

[17] Salek, R. M., et al. (2007). A metabolomic comparison of urinary changes in type 2 diabetes in mouse, rat, and human. *Physiological Genomics, 29*(2), 99–108. doi:10.1152/physiolgenomics.00194.2006

[18] Maltesen, R. G., Wimmer, R., & Rasmussen, B. S. (2020). A longitudinal serum NMR-based metabolomics dataset of ischemia-reperfusion injury in adult cardiac surgery. *Scientific Data, 7*, 198. doi:10.1038/s41597-020-0545-0

[19] Engelke, U. F. H., Tangerman, A., Willemsen, M. A. A. P., Moskau, D., Loss, S., Mudd, S. H., & Wevers, R. A. (2005). Dimethyl sulfone in human cerebrospinal fluid and blood plasma confirmed by one-dimensional ^{1}H and two-dimensional ^{1}H–^{13}C NMR. *NMR in Biomedicine, 18*(5), 331–336. doi:10.1002/nbm.966

[20] Varma, S., & Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics, 7*, 91. doi:10.1186/1471-2105-7-91

[21] Adebayo, J., Gilmer, J., Muelly, M., Goodfellow, I., Hardt, M., & Kim, B. (2018). Sanity checks for saliency maps. *Advances in Neural Information Processing Systems, 31*.

[22] Kumar, I. E., Venkatasubramanian, S., Scheidegger, C., & Friedler, S. (2020). Problems with Shapley-value-based explanations as feature importance measures. *Proceedings of the 37th International Conference on Machine Learning (ICML)*, PMLR 119, 5491–5500.